

Přednáška 2

Asymptotická složitost (časová složitost)

Insert sort – podrobnější analýza algoritmu


Selection Sort, Bubble Sort – ukázka kódu

Plán

- Třídění (InsertSort)
- Analýza – nejhorší případ
 - Insert Sort (Třídění vkládáním): Jak to funguje?
- Asymptotická složitost (časová složitost) – je náš algoritmus dostatečně rychlý pro naše data?
 - Insertion Sort: Je dostatečně rychlý?
- Selection Sort, Bubble Sort

Řazení

- Důležité – jednoduchý přístup:
 - Seřadíme prvky – budeme potřebovat jen jedno pole – třídění na místě
 - Použité operace – pouze porovnání a přesun prvků
- Stabilita - zachování pořadí prvků se stejnou hodnotou
 - Jednoduché algoritmy většinou ANO
 - Složitější algoritmy většinou NE



Délka posloupnosti (pole) je n

Insert Sort (Třídění vkládáním)

Začneme tím, že posouváme A [1]
na začátek seznamu, dokud
nenarazíme menší prvek (nebo už
nemůžete dále):

6	4	3	8	5
---	---	---	---	---

Index pole:

0	1	2	3	4
6	4	3	8	5
4	6	3	8	5

Potom posuneme A[2]: ↓

4	6	3	8	5
3	4	6	8	5

Potom posuneme A[3]:

3	4	6	8	5
3	4	6	8	5

Potom posuneme A[4]: ↓

3	4	6	8	5
3	4	5	6	8

Hotovo!

Celý algoritmus

//Vstup: neseříděné pole <type> [] A

//Výstup: seříděné pole <type> [] A

```
for (int i = 1; i<n; i++)  
{  
    t = A[i];  
    j = i - 1;  
    while (t < A[j]) {  
        A[j+1] = A[j];  
        j = j - 1;  
        if (j < 0) break;  
    }  
    A[j+1] = t;  
}
```

Celý algoritmus - Python

```
def InsertSort1(A):  
    for x in A:  
        B = [None for i in range(len(A))]  
        for i in range(len(B)):  
            if B[i] == None or B[i] > x:  
                j = len(B)-1  
                while j > i:  
                    B[j] = B[j-1]  
                    j -= 1  
                B[i] = x  
                break  
    return B
```

Jedna verze nebo jiná
verze

```
def InsertSort2(A):  
    for i in range(1, len(A)):  
        current = A[i]  
        j = i-1  
        while j >= 0 and A[j] > current:  
            A[j+1] = A[j]  
            j -= 1  
        A[j+1] = current
```

Insert Sort

1. Funguje to – můžeme formálně dokázat?
2. Je to dost rychlé – asymptotická složitost?

Tvrzení: Insert sort „funguje“

- „Důkaz:“ Právě to fungovalo v tomto příkladu:

6	4	3	8	5
---	---	---	---	---

6	4	3	8	5
4	6	3	8	5

4	6	3	8	5
3	4	6	8	5

3	4	6	8	5
3	4	6	8	5

3	4	6	8	5
3	4	5	6	8

Seřazeno!

Tvrzení: Insert sort „funguje“

"Důkaz:" Udělal jsem to na spoustě náhodných posloupností a vždy to fungovalo:

```
A = [1,2,3,4,5,6,7,8,9,10]
for trial in range(100):
    shuffle(A)
    InsertionSort(A)
    if is_sorted(A):
        print('YES IT IS SORTED!')
```


[illegible]

Co to znamená, že to „funguje“?

- Stačí, když je to správné pouze na jednom vstupu?
- Stačí, když je to správné na více vstupech?
- Ve naší výuce budeme používat analýzu **nejhoršího případu**:
 - Algoritmus musí být správný na všech možných vstupech.
 - Doba běhu algoritmu je nejhorší možná doba běhu přes všechny vstupy.

Proč to funguje?

- Řekněme, že máme seřazený seznam, a další prvek .



- Vložíme 5 hned po největším prvku, který je stále menší než 5. (Tedy, hned po 4).
- Získáme seřazený seznam:



Tuto logiku tedy použijeme u každého kroku.



První prvek [6] tvoří seřazený seznam.



Správné vložení 4 do seznamu [6] znamená, že se z [4, 6] stane seřazený seznam.



První dva prvky [4, 6] tvoří seřazený seznam.




Správné vložení 3 do seznamu [4, 6] znamená, že se z [3, 4, 6] stane seřazený seznam.



První tři prvky [3, 4, 6] tvoří seřazený seznam.



Správné vložení 8 do seznamu [3, 4, 6] znamená, že se z [3, 4, 6, 8] stane seřazený seznam.



První čtyři prvky [3, 4, 6, 8] tvoří seřazený seznam.



Správné vložení 5 do seznamu [3, 4, 6, 8] znamená, že se z [3, 4, 5, 6, 8] stane seřazený seznam.

HOTOVO!

Použijeme důkaz indukcí ...

Matematická indukce je jedna ze základních důkazových metod, která se obvykle používá, chceme-li dokázat, že nějaké tvrzení či matematická věta platí pro všechna přirozená čísla.

Důkaz matematickou indukcí spočívá ve dvou krocích:

1. Tvrzení dokážeme pro $n = 1$
2. Předpokládáme, že tvrzení platí pevně zvolené $n = k$.

Z tohoto indukčního předpokladu dokážeme, že platí i pro $n = k + 1$.

(viz doprovodný text v Moodle)

Poznámka: v Pythonu lze zapsat: `x[:j] = x[0 : j]`
Příklad:
`a=[6,7,5,2,9]`
`print(a[: 3])`
Výsledek: `[6, 7, 5]`

Nástin důkazu indukcí

Nechť A je seznam délky n

- **Induktivní hypotéza:**
 - $A[:i+1]$ bude seřazeno na konci i -té iterace (vnější smyčky).
- **Základní případ ($i = 0$):**
 - $A[:1]$ bude seřazeno na konci 0-té iterace. ✓
- **Induktivní krok:**
 - Pro libovolné $0 < k < n$, jestliže pro $i = k - 1$ platí indukční hypotéza, potom také platí pro $i = k$.
 - Tudíž, jestliže $A[:k]$ je setříděno v kroku $k-1$, potom $A[:k+1]$ je setříděno v kroku k
- **Závěr:**
 - Induktivní hypotéza platí pro $i = 0, 1, \dots, n-1$.
 - Zejména platí pro $i = n-1$.
 - Na konci $n-1$ -té iterace (tudíž na konci běhu algoritmu), $A[:n] = A$ je seřazené pole.
 - To jsme chtěli! ✓

Postupujeme pomocí této logiky



První dva prvky $[4, 6]$ tvoří seřazený seznam.



Správné vložení 3 do seznamu $[4, 6]$ znamená, že se z $[3, 4, 6]$ stane seřazený seznam.


To byla iterace $i = 2$.

Asymptotická složitost algoritmu (časová složitost)

- **Zjednodušení: obvykle místo asymptotická složitost algoritmu říkáme pouze *složitost algoritmu* (*časová složitost*).**


Jak rychlé je řazení Insert sort?

- Takto rychlý:



Problémy s touto odpovědí?

- „Stejný“ algoritmus může být pomalejší nebo rychlejší v závislosti na implementaci.
- Může to být také pomalejší nebo rychlejší v závislosti na hardwaru, na kterém jej provozujeme.



Jak rychlý je Insert sort?

- Spočítejme počet operací!

```
def InsertionSort(A):  
    for i in range(1, len(A)):  
        current = A[i]  
        j = i-1  
        while j >= 0 and A[j] > current:  
            A[j+1] = A[j]  
            j -= 1  
        A[j+1] = current
```

Spočítáme operace *...

- $2n^2 - n - 1$ přiřazení
- $2n^2 - n - 1$ inkrementování/dekrementování
- $2n^2 - 4n + 1$ porovnání
- ...

* Nebudeme teď věnovat pozornost těmto vzorcům, na nich teď nezáleží. Ukážeme si to ještě na příkladu.

Problémy s touto odpovědí?

- Je to velmi zdlouhavé!
- Abych to mohl použít k pochopení doby běhu, potřebuji vědět, jak dlouho každá operace trvá, plus spoustu dalších věcí ...

```
def InsertionSort(A):  
    for i in range(1, len(A)):  
        current = A[i]  
        j = i-1  
        while j >= 0 and A[j] > current:  
            A[j+1] = A[j]  
            j -= 1  
        A[j+1] = current
```

Budeme používat ...

- **Velké-Oh notaci!**
- Poskytuje nám smysluplný způsob, jak hovořit o době chodu algoritmu, nezávisle na programovacím jazyce, výpočetní platformě atd., a aniž bychom museli počítat všechny operace jako v předchozím případě.
- Poskytuje na jednoduchý způsob, jak vystihnout chování algoritmu při různé velikosti vstupu (různých n)

Hlavní myšlenka :

Zaměříme se na to, jak se doba běhu mění s n (velikost vstupu).

Nějaké příklady ...

(Budeme věnovat pozornost pouze největší funkci n , která se ve funkci objeví (říkáme ji také řád růstu funkce))

Počet operací	Asymptotická doba běhu
$\frac{1}{10} \cdot n^2 + 100$	$O(n^2)$
$0.063 \cdot n^2 - .5 n + 12.7$	$O(n^2)$
$100 \cdot n^{1.5} - 10^{10000} \sqrt{n}$	$O(n^{1.5})$
$11 \cdot n \log(n) - 1$	$O(n \log(n))$

Říkáme, že tento algoritmus je „asymptoticky rychlejší“ než ostatní.

Proč je to dobrý nápad?

- Předpokládejme, že doba běhu algoritmu je :

$$T(n) = 10n^2 + 3n + 7 \text{ ms}$$

Tento konstantní faktor 10
hodně závisí na mé
výpočetní platformě ...

Pak nám zbývá výraz n^2 ! To je to,
co je smysluplné.

Na těchto výrazech
nižšího řádu ve
skutečnosti moc
nezáleží, jak se n
(velikost vstupu)
zvětšuje.

Výhody a nevýhody asymptotické časové složitosti

Výhody:

- Abstrahuje od problémů specifických pro hardware a programovací jazyk.
- Díky analýze algoritmu je mnohem přehlednější a zvládnutější.
- Umožňuje nám smysluplně porovnat, jak budou algoritmy fungovat na velkých vstupech.

Nevýhody:


- Dává smysl pouze v případě, že n je velké (i ve srovnání s konstantními faktory).

1000000000 n
je “lepší” než n^2 !?!

Výhody a nevýhody asymptotické analýzy

Pro malá n nemusí být nutně algoritmus s nižší složitostí rychlejší(výhodnější)

např. n^2 vs. $50n + 500$



vyslovuje se „big-oh of...” nebo někdy „ach ...”

Neformální definice pro $O(\dots)$


- Necht' $T(n)$, $g(n)$ jsou funkce definované na množině kladných celých čísel.
 - Představte si $T(n)$ jako dobu běhu: je kladná a rostoucí na n .
- Řekneme, že “ $T(n)$ je $O(g(n))$ ” jestliže:
pro dostatečně velká n (tj. pro $n > n_0$,)
 $T(n)$ je menší nebo rovna násobku nějaké konstanty
a funkce $g(n)$.

„Konstanta“ zde znamená „nějaké číslo,
které nezávisí na n ”.

Příklad

$$2n^2 + 10 = O(n^2)$$


pro dostatečně velké n je $T(n)$
nanejvýš násobek nějaké
konstanty a funkce $g(n)$.



Příklad

$$2n^2 + 10 = O(n^2)$$


pro dostatečně velké n je $T(n)$
nanejvýš násobek nějaké
konstanty a funkce $g(n)$.



Příklad

$$2n^2 + 10 = O(n^2)$$

pro dostatečně velké n je $T(n)$
nanejvýš násobek nějaké
konstanty a funkce $g(n)$.



Formální definice $O(\dots)$

- Nechť $T(n)$, $g(n)$ jsou funkce definované na množině kladných celých čísel.
 - Představte si $T(n)$ jako dobu běhu: je kladná a rostoucí na n .
- Formálně,

$$T(n) = O(g(n))$$

“právě tehdy, když” $\longrightarrow \iff$ “pro všechna”

“existuje” $\nearrow \exists c, n_0 > 0 \text{ s. t. } \forall n \geq n_0,$

$T(n) \leq c \cdot g(n)$ “taková že (such that)”

Příklad


$$2n^2 + 10 = O(n^2)$$

$$T(n) = O(g(n))$$

$$\Leftrightarrow$$

$$\exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0,$$

$$T(n) \leq c \cdot g(n)$$



Příklad


$$2n^2 + 10 = O(n^2)$$

$$T(n) = O(g(n))$$

$$\Leftrightarrow$$

$$\exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0,$$

$$T(n) \leq c \cdot g(n)$$



Příklad


$$2n^2 + 10 = O(n^2)$$

$$T(n) = O(g(n))$$

$$\Leftrightarrow$$

$$\exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0,$$

$$T(n) \leq c \cdot g(n)$$



Příklad


$$2n^2 + 10 = O(n^2)$$

$$T(n) = O(g(n))$$

$$\Leftrightarrow$$

$$\exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0,$$

$$T(n) \leq c \cdot g(n)$$



Formálně:

- Zvolíme $c = 3$
- Zvolíme $n_0 = 4$
- Potom:

$$\forall n \geq 4,$$

$$2n^2 + 10 \leq 3 \cdot n^2$$

Jiný příklad


$2n^2 + 10 = O(n^2)$

$$T(n) = O(g(n))$$

$$\Leftrightarrow$$

$$\exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0,$$

$$T(n) \leq c \cdot g(n)$$



Formálně:

- Zvolíme $c = 7$
- Zvolíme $n_0 = 2$
- Potom:


$$\forall n \geq 2,$$

$$2n^2 + 10 \leq 7 \cdot n^2$$

Neexistuje
„správná“ volba c
a n_0

$O(\dots)$ je horní mez :
 $n = O(n^2)$

$$\begin{aligned} T(n) = O(g(n)) \\ \Leftrightarrow \\ \exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0, \\ T(n) \leq c \cdot g(n) \end{aligned}$$



- Zvolíme $c = 1$
- Zvolíme $n_0 = 1$
- Potom

$$\forall n \geq 1, \\ n \leq n^2$$

$\Omega(\dots)$ znamená dolní hranici

- Řekneme, že “ $T(n)$ je $\Omega(g(n))$ ” jestliže pro dostatečně velká n , $T(n)$ je nejméně tak velká jako funkce $g(n)$ vynásobená zvolenou konstantou.
- Formálně,

$$\begin{aligned} T(n) &= \Omega(g(n)) \\ &\iff \\ \exists c, n_0 > 0 \text{ s. t. } \forall n \geq n_0, \\ &\quad c \cdot g(n) \leq T(n) \end{aligned}$$

Příklad


$n \log_2(n) = \Omega(3n)$

$$T(n) = \Omega(g(n))$$

$$\Leftrightarrow$$

$$\exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0,$$

$$c \cdot g(n) \leq T(n)$$



- Zvolíme $c = 1/3$
- Zvolíme $n_0 = 2$
- Potom

$$\forall n \geq 2,$$

$$\frac{3n}{3} \leq n \log_2(n)$$

$\Theta(\dots)$ znamená obojí!

- Řekneme, že “ $T(n)$ je $\Theta(g(n))$ ” jestliže platí zároveň:

$$T(n) = O(g(n))$$

a

$$T(n) = \Omega(g(n))$$

Dokažmě, že: n^2 není $O(n)$

$$\begin{aligned} T(n) = O(g(n)) &\Leftrightarrow \\ \exists c, n_0 > 0 \text{ s.t. } \forall n \geq n_0, & \\ T(n) \leq c \cdot g(n) & \end{aligned}$$

- Důkaz sporem:
- Předpokládejme, že $n^2 = O(n)$.
- Potom existují nějaká kladná čísla c a n_0 taková, že:

$$\forall n \geq n_0, \quad n^2 \leq c \cdot n$$

- Podělíme obě strany číslem n :

$$\forall n \geq n_0, \quad n \leq c$$

- To ale není pravda!!!
- Co když řekneme, že $n_0 = c + 1$?
 - Potom pro $n \geq c + 1$ vychází $n \leq c$
- Spor!

Podobné příklady

- Abychom dokázali, že $T(n) = O(g(n))$, musíme přijít s c a n_0 takovými, že splňují definici.
- Abychom dokázali, že $T(n)$ **NENÍ** $O(g(n))$, jeden ze způsobů je **důkaz sporem**:
 - Předpokládejme (abychom se později dostali ke sporu), že „něco“ nám dá c a n_0 takové, že definice **je** splněna.
 - Poté ukážeme, že to „něco“ nám dává nepravdivou informaci a tím „odvodíme“ **spor**.

tedy

- Řekneme, že $p(n) = a_k n^k + a_{k-1} n^{k-1} + \dots + a_1 n + a_0$ je polynom stupně $k \geq 1$.
- Potom:
 1. $p(n) = O(n^k)$
 2. $p(n)$ není $O(n^{k-1})$

Další příklady

- $n^3 + 3n = O(n^3 - n^2)$
- $n^3 + 3n = \Omega(n^3 - n^2)$
- $n^3 + 3n = \Theta(n^3 - n^2)$

- 3^n **NENÍ** $O(2^n)$
- $\log_2(n) = \Omega(\ln(n))$
- $\log_2(n) = \Theta(2^{\log\log(n)})$

Zkuste sami provést
důkazy!

K zamyšlení, poznámka


- Existují funkce f, g takové, že **ANI** $f = O(g)$ ani $f = \Omega(g)$?
- Existují nějaké **ne-klesající** funkce f, g takové, že shora tvrzení platí?

Poznámka

- Asymptotická notace
- Zanedbáváme nižší řády a multiplikativní konstanty, ale musíme být přitom opatrní.
- Zde probíráme praktické algoritmy, takže nemusíme volit $n \geq n_0 = 2^{100000000}$.

Zpět k insert sortu


1. Pracuje?
2. Je rychlý?



Insertion Sort: doba běhu

- Počet operací byl:
 - $2n^2 - n - 1$ přiřazení
 - $2n^2 - n - 1$ inkrement/dekrement
 - $2n^2 - 4n + 1$ porovnání
 - ...
- Doba běhu je $O(n^2)$

Podívej se na pseudokód a
přesvědč se o tom!



To se zdá
rozumné

Insert sort: doba běhu

Často můžeme odhadnou dobu běhu z pseudokódu, například bychom odhadli...

```
def InsertionSort(A):  
    for i in range(1, len(A)):  
        prvek = A[i]  
        j = i-1  
        while j >= 0 and A[j] > prvek:  
            A[j+1] = A[j]  
            j -= 1  
        A[j+1] = prvek
```

n-1 iteraci ve
vnějším cyklu

V nejhorším
případě přibližně n
iterací v tomto
vnitřním cyklu

Tedy vnitřní cyklus se opakuje n x, tedy
dostáváme $O(n^2)$."

Závěr

Insert sort je algoritmus, který správně seřadí libovolné n -rozměrné pole v čase $O(n^2)$.

Dle řádu funkce dostaly některé složitosti i své jméno

- $O(1)$ –konstantní
- $O(\log N)$ –logaritmická
- $O(N)$ –lineární
- $O(N \log N)$ –lineárně-logaritmická (supralineární)
- $O(N^2)$ –kvadratická
- $O(N^3)$ –kubická
- Obecně $O(N^x)$ –polynomiální
- Obecně $O(X^N)$ –exponenciální
- $O(N!)$ –faktoriálová

Pro představu: Máme počítač s rychlostí 1 megaFLOPS. Jak dlouho bude počítat?

<i>složitost / N</i>	10	20	40	60	500	1000
$\log_2 N$	3,3 μ s	4,3 μ s	5 μ s	5,8 μ s	9 μ s	10 μ s
N	10 μ s	20 μ s	40 μ s	60 μ s	0,5 ms	1 ms
$N \log_2 N$	33 μ s	86 μ s	0,2 ms	0,35 ms	4,5 ms	10 ms
N^2	0,1 ms	0,4 ms	1,6 ms	3,6 ms	0,25 s	1 s
N^3	1 ms	8 ms	64 ms	0,2 s	125 s	17 min
N^4	10 ms	160 ms	2,56 s	13 s	17 hod	11,6 dnů
2^N	1 ms	1 s	12,7 dnů	36000 let	10^{137} let	10^{287} let
$N!$	3,6 s	77000 let	10^{34} let	10^{68} let	10^{1110} let	10^{2554} let

„**Domácí úkol**“: Zjistěte, jaký výkon má současný nejrychlejší superpočítač.
Jak dlouho by řešil algoritmus s exponenciální složitostí pro $N=1000$?

Prostorová (paměťová) složitost

- Složitost prostorová – spotřeba paměti, diskového prostoru v závislosti na vstupních datech.
- Lze analyzovat podobně, jako jsem to dělali u časové složitosti.
- Časová složitost je to, o co nám většinou jde. Nebudeme se prostorovou (paměťovou) složitostí dále zabývat.

Další algoritmy

- Selection sort (Řazení výběrem)
- Bubble sort (Metoda přímé výměny)

Selection Sort

- Selection sort (Řazení výběrem)
- Snaha minimalizovat počet časově náročných operací – přesunů
- V každém kroku i algoritmu se vybere nejmenší prvek posloupnosti $A[i]..A[n-1]$ a vymění se s prvkem $A[i]$
- Algoritmus

```
for(int i=0; i<n-1; i++) {  
    vyber nejmenší prvek  $A[k]$  z  $A[i]..A[n-1]$   
    vyměň  $A[k]$  s  $A[i]$   
}
```

Selection Sort – ukázka kódu

// Vstup: neseříděné pole <type> [] A

// Výstup: seříděné pole <type> [] A

```
for ( int i=0; i<n-1; i++) {  
    k=i; x=A[i];  
    for( int j=i+1; j<n; j++) {  
        if( A[j] <x) {  
            k=j; x=A[j];  
        }  
    }  
    if( k!=i) {  
        t=A[k]; A[k]=A[i]; A[i]=t;  
    }  
}
```

Vlastnosti algoritmu Selection Sort

- Složitost?

$O(n^2)$

- Co se zlepšilo?
 - počet přesunů
- Za jakou cenu?
 - zvýšení počtu porovnání

Bubble Sort (metoda přímé výměny)

- Bubble sort
- Založený na postupném porovnání a případné záměně sousedních prvků
- Prvky s nízkým klíčem postupně „probublávají“ na začátek pole (možný je i opačný postup, kdy prvky s vysokou hodnotou „probublávají“ na konec pole).

Bubble Sort – příklad kódu

```
// Vstup: neseříděné pole <type> [] A
//Výstup: seříděné pole <type> [] A
for ( int i = 1; i < n-1; i++) {
    for (int j = n-1; j >= i; j--)    {
        if(A[j-1] > A[j])
        {
            t = A[j-1];
            A[j-1] = A[j];
            A[j] = t;
        }
    }
}
```


Bubble Sort

- Vlastnosti
- Složitost: $O(n^2)$
- Co jsme ušetřili?
 - nic! – bublinkové třídění je ve většině případů nejpomalější
- Kdy je dobré?
 - když je pole téměř setříděno

Konec – co jsme probrali

- Pojem asymptotická složitost algoritmů
- Algoritmy patřící do skupiny kvadratických algoritmů, které správně seřadí libovolné n -rozměrné pole v čase $O(n^2)$ (říkáme také se složitostí $O(n^2)$):
 - Insert sort – analyzovali jsme podrobněji
 - Selection sort
 - Bubble sort